

Analyse des données de santé

(Système Business Intelligent)

2ème année en cycle d'Ingénierie

Filière : Systèmes d'informations et big data

Analyse Multi-facettes avec SSMS, SSIS et Power BI

Encadré par : Hamid HERIMECH

Préparé par : Majda EL HASNAOUI & Fatima EL BOUTAHRI

Année universitaire : 2023/2024

Résumé

Ce projet de fin de module pour le Système Business Intelligent se concentre sur l'analyse des données de santé à travers une approche intégrée impliquant Microsoft SQL Server Management Studio (SSMS), Microsoft SQL Server Integration Services (SSIS), et Power BI.

L'objectif principal est d'extraire, transformer et charger (ETL) En combinant des données provenant de sources multiples et variées, telles que les dossiers médicaux électroniques, les enquêtes sur la santé publique, ou les appareils de suivi de la condition physique, puis de les analyser et de les visualiser de manière significative pour obtenir des insights exploitables.

En se concentrant spécifiquement sur l'outil Power BI, ce projet met en évidence la capacité de cette plateforme à transformer des données brutes en visualisations interactives et informatives. Power BI permet de dresser un tableau complet de la santé générale des individus.

Introduction

Dans un monde de plus en plus axé sur les données, l'analyse des données de santé est devenue une composante essentielle pour comprendre et améliorer la santé et le bien-être des individus. Avec l'essor des technologies de l'information, les professionnels de la santé disposent désormais d'outils puissants pour collecter, stocker, et analyser des données de santé à une échelle sans précédent.

Ce projet se concentre sur l'utilisation de Power BI pour fournir une vue d'ensemble de l'état de santé général des individus. L'objectif est d'exploiter les données disponibles pour obtenir des insights significatifs sur différents aspects de la santé, tels que la santé physique et mentale, les habitudes de vie, etc.

À travers cette introduction, nous explorerons donc les défis et les opportunités liés à l'analyse des données de santé, ainsi que le rôle crucial de Power BI dans la création d'une vue d'ensemble claire et précise de la santé des individus. En fin de compte, ce projet vise à fournir des insights exploitables pour soutenir la prise de décisions éclairées en matière de santé et de bien-être.

Comment l'utilisation de Power BI peut-elle fournir une vue d'ensemble précise de l'état de santé général des individus et contribuer à des décisions stratégiques informées dans le domaine de la santé et du bien-être ?

Table des matières


I. Méthodologie :	7
1. Microsoft SQL Server Management Studio	8
2. Microsoft SQL Server Integration Services	8
3. Power Bi	9
II. Le processus ETL :	10
1. Extraction des données	10
2. Transformation des données	11
3. Chargement des données :	12
III. Conception du datawarehouse :	14
1. Tables des dimensions :	14
2. Table de faits :	15
IV. Analyse des données avec Power BI	16
V. Conclusion	17

Table des figures

Figure 1 : Extrait du dataset.....	11
Figure 2 : Process de chargement des données	12
Figure 3 : Process ETL - alimentation du Datawarehouse	13
Figure 4 : Schème du Datawarehouse.....	15
Figure 5 : Tableau de bord.....	16

I. Méthodologie :

La méthodologie joue un rôle essentiel dans tout projet d'analyse des données, fournissant un cadre structuré pour la collecte, la préparation et l'analyse des données. Dans le cadre de ce rapport, nous explorerons la méthodologie utilisée pour intégrer les outils de Microsoft SQL Server Management Studio (SSMS), Microsoft SQL Server Integration Services (SSIS) et Power BI dans le processus d'analyse des données de santé.



1. Microsoft SQL Server Management Studio

Communément appelé SSMS, ce logiciel développé par Microsoft offre une gamme complète de fonctionnalités pour **la gestion, le développement** et **la maintenance** de bases de données SQL Server.



Initialement lancé en 2005 en tant qu'outil indépendant, il a ensuite été intégré à d'autres environnements de développement de Microsoft tels que Visual Studio. Au fil des ans, il a évolué et est devenu incontournable pour les **administrateurs et développeurs SQL**.

Il s'agit d'une **solution puissante et polyvalente**, apportant de multiples avantages. Tout d'abord, elle permet aux administrateurs de gérer toutes leurs bases de données SQL Serveur depuis une seule interface. Leur travail quotidien s'en trouve grandement simplifié

2. Microsoft SQL Server Integration Services

SQL Server Integration Services est une plateforme qui permet de créer des solutions de transformation et d'intégration de données au niveau de l'entreprise.

SQL Server Integration Services résout les problèmes d'intégration ou d'échange de données complexes en copiant ou en téléchargeant des fichiers, en envoyant des messages électroniques en réponse à des événements, en mettant à jour des entrepôts de données, en nettoyant, en vérifiant l'intégrité / la qualité des données et, enfin, en explorant des données et en gérant des données et des objets SQL Server.



3. Power Bi



Power BI est un ensemble de services logiciels, d'applications et de connecteurs qui œuvrent ensemble pour transformer des sources de données disparates en **Power BI** insights cohérents, visuellement immersifs et interactifs.

Les données peuvent être sous forme de feuille de calcul Excel ou de collection d'entrepôts de données hybrides locaux ou sur le cloud. Power BI permet de se connecter facilement aux sources de données, de visualiser et de découvrir ce qui est important, et de partager ces informations pertinentes.

II. Le processus ETL :

1. Extraction des données

Dans cette analyse, les données ont été extraites du **Behavioral Risk Factor Surveillance System (BRFSS)** de 2020, géré par les **Centers for Disease Control and Prevention (CDC)** aux États-Unis. Le BRFSS est une enquête téléphonique annuelle qui recueille des informations sur les comportements de santé, les conditions médicales et les caractéristiques démographiques des participants dans tout le pays.

Les données du BRFSS de 2020 peuvent être consultées et téléchargées à partir du site Web des CDC via le lien suivant : [lien](#). (75k lignes & 36 colonnes)

	A ⁰ _C State	A ⁰ _C Sex	A ⁰ _C GeneralH...	Y ² ₃ PhysicalHealth...	Y ² ₃ MentalHealthDays	A ⁰ _C LastCheckupTime	A ⁰ _C PhysicalActi...	Y ² ₃ SleepHo...	A ⁰ _C HadHeartAttack
1	Alabama	Female	Very good	4	0	Within past year (anytime less than 12 months ago)	Yes	9	No
2	Alabama	Male	Very good	0	0	Within past year (anytime less than 12 months ago)	Yes	6	No
3	Alabama	Male	Very good	0	0	Within past year (anytime less than 12 months ago)	No	8	No
4	Alabama	Female	Fair	5	0	Within past year (anytime less than 12 months ago)	Yes	9	No
5	Alabama	Female	Good	3	15	Within past year (anytime less than 12 months ago)	Yes	5	No
6	Alabama	Male	Good	0	0	Within past year (anytime less than 12 months ago)	Yes	7	No
7	Alabama	Female	Good	3	0	Within past year (anytime less than 12 months ago)	Yes	8	No
8	Alabama	Male	Fair	5	0	Within past year (anytime less than 12 months ago)	Yes	8	Yes
9	Alabama	Male	Good	2	0	5 or more years ago	No	6	No
10	Alabama	Female	Very good	0	0	Within past year (anytime less than 12 months ago)	Yes	7	No
11	Alabama	Male	Very good	0	0	Within past year (anytime less than 12 months ago)	Yes	8	No
12	Alabama	Female	Good	3	4	Within past year (anytime less than 12 months ago)	Yes	5	No
13	Alabama	Male	Good	5	0	Within past year (anytime less than 12 months ago)	Yes	5	Yes
14	Alabama	Female	Good	0	0	Within past year (anytime less than 12 months ago)	No	6	No
15	Alabama	Male	Fair	25	25	Within past year (anytime less than 12 months ago)	No	6	No
16	Alabama	Female	Good	0	15	Within past year (anytime less than 12 months ago)	Yes	8	No
17	Alabama	Female	Good	0	0	Within past year (anytime less than 12 months ago)	Yes	7	No
18	Alabama	Female	Good	0	0	Within past year (anytime less than 12 months ago)	No	10	No
19	Alabama	Female	Excellent	0	0	Within past year (anytime less than 12 months ago)	Yes	6	No
20	Alabama	Male	Poor	30	0	Within past year (anytime less than 12 months ago)	No	9	No
21	Alabama	Female	Fair	30	0	Within past year (anytime less than 12 months ago)	No	8	No
22	Alabama	Male	Good	4	0	Within past year (anytime less than 12 months ago)	No	10	No
23	Alabama	Female	Very good	0	5	Within past year (anytime less than 12 months ago)	Yes	9	No
24	Alabama	Female	Very good	0	30	Within past 2 years (1 year but less than 2 years ago)	Yes	8	No
25	Alabama	Female	Fair	30	0	Within past year (anytime less than 12 months ago)	No	7	No
26	Alabama	Female	Poor	4	0	Within past year (anytime less than 12 months ago)	No	7	No
27	Alabama	Female	Good	3	0	Within past year (anytime less than 12 months ago)	Yes	7	No

Figure 1 : Extrait du Dataset

2. Transformation des données

Après avoir extrait les données du Behavioral Risk Factor Surveillance System (BRFSS) de 2020, la prochaine étape consistait à nettoyer et à préparer les données pour l'analyse. Cette étape cruciale a été réalisée en utilisant **Power Query**, un outil intégré permettant d'effectuer des transformations de données avancées.

Dans un premier temps, les données ont été examinées pour identifier et éliminer les éventuelles erreurs ou incohérences. Cela comprenait la suppression des lignes contenant des valeurs manquantes ou des données incorrectes, ainsi que la correction des erreurs de saisie ou des valeurs aberrantes.

Ensuite, les types de données ont été ajustés pour chaque colonne afin de refléter correctement le contenu de la donnée. Par exemple, les variables numériques ont été converties en types numériques appropriés (entiers ou décimaux), et les variables catégorielles ont été converties en types de données textuelles.

Enfin, des étapes de nettoyage supplémentaires ont été effectuées selon les besoins spécifiques du projet, telles que la fusion ou la division de colonnes, la création de colonnes calculées, ou l'agrégation des données pour obtenir des agrégats significatifs.

3. Chargement des données :

Le chargement des données peut être réalisé à l'aide de divers outils et méthodes, selon les besoins spécifiques du projet. Dans notre cas, nous avons utilisé Microsoft SQL Server Integration Services (SSIS) pour automatiser le chargement des données dans les tables de destination.




Figure 2 : Process de chargement des données

Une fois que la base de données a été créée et que les données de notre ensemble de données y ont été intégrées, nous procédons à son exploitation pour alimenter les différentes tables de notre entrepôt de données. Nous commençons par initialiser et vider les tables de dimensions, afin de les préparer pour le chargement ultérieur à l'aide de requêtes SQL. Ensuite, nous remplissons la table de faits à partir des tables de dimensions et de la base de données initiale, en utilisant des jointures tout en maintenant l'intégrité des clés étrangères. La figure ci-dessus illustre l'intégralité du processus ETL élaboré.




Figure 3 : Process ETL - alimentation du Datawarehouse

III. Conception du datawarehouse :

Dans la conception de notre datawarehouse, nous avons adopté le schéma en étoile. Il se compose d'une table de fait centrale contenant les mesures clés de notre système, entourée de trois tables de dimensions distinctes. Ces dimensions, sans hiérarchie, permettent une analyse détaillée et une compréhension approfondie de nos données à travers différentes perspectives.

1. Tables des dimensions :

Une table de dimension est une table de base de données qui complète les données dans une table référentielle mappée à une table de base de données.

- ✓ Table Gender : Cette table est utilisée comme une dimension pour distinguer par sexe (Homme/Femme).
- ✓ Table State : Cette table contient les différents États des États-Unis afin de faciliter l'analyse de l'état de santé général par État.
- ✓ Table Age Category : Cette table contient les différentes tranches d'âge regroupées par intervalles de 4 ans, permettant l'analyse de l'état de santé général par groupe d'âge.
- ✓ Table Body Vital Statistics : Cette dimension complémentaire présente des données relatives aux statistiques vitales du corps, telles que la taille, le poids et l'indice de masse corporelle (BMI)..

2. Table de faits :

La table de fait contient l'ensemble des mesures correspondant aux informations de l'activité à analyser.

FACT_HEALTH : Contient des données de santé individuelles, telles, les jours de santé physique et mentale




Figure 4 : Schème du Datawarehouse

IV. Analyse des données avec Power BI

Les **tableaux de bord Power BI**, ou dashboards Power BI, sont connus pour leur force visuelle et leur concision qui les ont rendus très populaires. Comme tout tableau de bord de suivi, ils illustrent un ensemble d'indicateurs de performance (ou KPI) afin de faciliter la prise de décision.

Voici le tableau de bord qui illustre : Health Status Overview




Figure 5 : Tableau de board

V. Conclusion

En conclusion, ce rapport a exploré une méthodologie complète pour l'analyse des données de santé en utilisant Microsoft SQL Server Management Studio, SQL Server Integration Services et Power BI. Nous avons examiné chaque étape du processus ETL, la conception du datawarehouse et l'analyse des données avec Power BI. En intégrant ces outils et méthodes, nous sommes en mesure de fournir des insights précieux pour améliorer les soins de santé et la gestion des ressources médicales.